

Pesquise os benchmarks / datasets mais confiáveis para avaliar agentic ai models (claude code, codex...) que avalie de maneira robusta a capacidade do modelo (tendo ele scaffold ou não), utilize diversas linguagens e tecnologias (desde python até rust/go) e seja referência acadêmica.

Benchmarks Acadêmicos para Coding Agents

Os subtemas centrais aqui são **robustez da avaliação agentic**, **cobertura multilíngue/tecnológica** e **independência de scaffold**, porque um benchmark confiável precisa separar habilidade do modelo, dificuldade do ambiente e risco de overfitting ao próprio benchmark (Jimenez et al., 2023; Zhuge et al., 2024; Ferrag et al., 2025).

Benchmarks Recomendados

Para avaliar Claude Code, Codex e agentes similares de forma academicamente forte, o núcleo hoje é **combinar benchmarks repository-level e end-to-end**, não depender de um único teste estilo HumanEval (Jimenez et al., 2023; Zhuge et al., 2024; Zhang et al., 2026).

Benchmark	O que mede melhor	Linguagens / escopo	Por que é confiável
SWE-bench / Verified	Resolução de issues reais em repositórios	Python, 2.294 problemas	Referência acadêmica de facto para agents; patches avaliados por testes reais (Jimenez et al., 2023; Rashid et al., 2025)
SWE-PolyBench	Avaliação repository-level multi-language	Python, Java, JavaScript, TypeScript	Execução automatizada, 2.110 instâncias, métricas via AST e análise por complexidade (Rashid et al., 2025)
Multi-SWE-bench	Issue resolving multilíngue	Java, TS, JS, Go, Rust, C, C++	1.632 instâncias com anotação por 68 especialistas; forte cobertura além de Python (Zan et al., 2025)
FeatureBench	Desenvolvimento de features complexas	Python repos, 200 tarefas	Muito mais difícil que SWE-bench; mede desenvolvimento feature-level e multi-PR (Zhou et al., 2026)
PRDBench / ProjDevBench	Construção de projeto a partir de requisitos	Python projetos / 20 problemas E2E	Avaliam PRD-to-code, revisão por agente ou code review, além de testes unitários (Fu et al., 2025; Lu et al., 2026)

FIGURE 1 Benchmarks mais recomendados para avaliar coding agents por escopo, linguagem e robustez.

A variação de desempenho por linguagem e complexidade fica visível em uma comparação estratificada por linguagem e dificuldade, o que importa porque muitos agentes parecem fortes em Python e caem fora desse eixo. (Figure 1: Pass rates of coding agents across programming languages (left) and across subsets of different complexities based on syntax tree nodes. The right plot categorizes changes by type (class or function) and scope (single or multiple), with 'No nodes' indicating no class or function changes and 'Mixed' requiring both.)

Como Cobrir Scaffold e Multilíngue

Se a meta é medir a **capacidade do modelo tendo scaffold ou não**, o desenho mais robusto é cruzar o mesmo modelo em múltiplos scaffolds e também usar benchmarks cuja saída final seja verificável por execução ou revisão estruturada (Zhou et al., 2026; Lu et al., 2026; Liu et al., 2025).

- **SWE-bench** continua sendo a base mais aceita para agents, mas cobre principalmente **bug fixing em Python** (Jimenez et al., 2023; Zhuge et al., 2024).
- **SWE-PolyBench** é hoje uma das melhores opções para comparar agentes em várias linguagens sob o mesmo protocolo repository-level (Rashid et al., 2025).
- **Multi-SWE-bench** é a melhor opção explícita para incluir **Go e Rust** com curadoria humana forte (Zan et al., 2025).

Limitações e Complementos

Nenhum benchmark isolado cobre bem **snippet generation, robustez, projeto inteiro, segurança e multilinguismo** ao mesmo tempo (Sonwane et al., 2026; Zhou et al., 2026).

- Para **robustez de geração**, ReCode perturba docstrings, nomes e sintaxe para testar estabilidade (Jiang et al., 2024).
- Para **bibliotecas e instruções complexas**, BigCodeBench cobre 1.140 tarefas Python com 723 chamadas de função em 139 bibliotecas (Jiang et al., 2024).
- Para **segurança**, SEC-bench mede PoC generation e patching em tarefas autênticas de security engineering (Lee et al., 2025).

Para uma bateria realmente confiável e acadêmica, a melhor combinação é **SWE-bench/Verified + SWE-PolyBench + Multi-SWE-bench + um benchmark end-to-end** como FeatureBench, PRDBench ou ProjDevBench, complementados por BigCodeBench ou ReCode para robustez localizada (Rashid et al., 2025; Zan et al., 2025; Zhou et al., 2026; Lu et al., 2026).

These search results were found and analyzed using Consensus, an AI-powered search engine for research. Try it at <https://consensus.app>. © 2026 Consensus NLP, Inc. Personal, non-commercial use only; redistribution requires copyright holders' consent.

References

- Ferrag, M., Tihanyi, N., & Debbah, M. (2025). From LLM Reasoning to Autonomous AI Agents: A Comprehensive Review. *IEEE Access*, 14, 84237-84285. <https://doi.org/10.1109/access.2026.3698694>
- Fu, L., Zhang, B., Guan, H., Zhu, Y., Qiu, L., Liu, W., Cao, X., Cai, X., Zhang, W., & Yu, Y. (2025). Automatically Benchmarking LLM Code Agents through Agent-driven Annotation and Evaluation. *Proc. of the 25th International Conference on Autonomous Agents and Multiagent Systems*. <https://doi.org/10.65109/hjfb4234>
- Jiang, J., Wang, F., Shen, J., Kim, S., & Kim, S. (2024). A Survey on Large Language Models for Code Generation. *ACM Transactions on Software Engineering and Methodology*, 35, 1 - 72. <https://doi.org/10.1145/3747588>
- Jimenez, C. E., Yang, J., Wettig, A., Yao, S.-Y., Pei, K., Press, O., & Narasimhan, K. (2023). SWE-bench: Can Language Models Resolve Real-World GitHub Issues?. *ArXiv, abs/2310.06770*. <https://doi.org/10.48550/arxiv.2310.06770>
- Lee, H., Zhang, Z., Lu, H., & Zhang, L. (2025). SEC-bench: Automated Benchmarking of LLM Agents on Real-World Software Security Tasks. *ArXiv, abs/2506.11791*. <https://doi.org/10.48550/arxiv.2506.11791>

- Liu, K., Pan, Y., Li, J., He, D., Xiang, Y., Du, Y., & Gao, T. (2025). ProjectEval: A Benchmark for Programming Agents Automated Evaluation on Project-Level Code Generation. 20205-20221. <https://doi.org/10.48550/arxiv.2503.07010>
- Lu, P.-R., Zhang, S., Hou, Y., Ye, L., Huang, C., Chen, Z., Zeng, J., Jiang, H., Liu, P.-F., & Yang, M.-H. (2026). ProjDevBench: Benchmarking AI Coding Agents on End-to-End Project Development. *ArXiv, abs/2602.01655*. <https://doi.org/10.48550/arxiv.2602.01655>
- Rashid, M., Bock, C., Yuan, Z., Buccholz, A., Esler, T., Valentin, S., Franceschi, L., Wistuba, M., Sivaprasad, P. T., Kim, W., Deoras, A., Zappella, G., & Callot, L. (2025). SWE-PolyBench: A multi-language benchmark for repository level evaluation of coding agents. *ArXiv, abs/2504.08703*. <https://doi.org/10.48550/arxiv.2504.08703>
- Sonwane, A., Tu, E.-S., Lu, W.-C., Beger, C., Larsen, C., Dhar, D., Chen, R., Pattanayak, R., Dang, T., Chen, G., Geng, G., Ellis, K., & Dutta, S. (2026). OmniCode: A Benchmark for Evaluating Software Engineering Agents. *ArXiv, abs/2602.02262*. <https://doi.org/10.48550/arxiv.2602.02262>
- Zan, D.-G., Huang, Z., Liu, W., Chen, H.-W., Zhang, L.-H., Xin, S.-L., Chen, L., Liu, Q., Zhong, X., Li, A.-Y., Liu, S., Xiao, Y., Chen, L.-Q., Zhang, Y., Su, J., Liu, T., Long, R., Shen, K., & Xiang, L. (2025). Multi-SWE-bench: A Multilingual Benchmark for Issue Resolving. *ArXiv, abs/2504.02605*. <https://doi.org/10.48550/arxiv.2504.02605>
- Zhang, Z., Zhang, H.-B., Fei, H., Bao, Z., Chen, Y., Lei, Z., Liu, Z.-Y., Sun, Y.-X., Xiao, M., Ye, Z., Zhang, Y., Zhu, H., Wen, Y., & Shum, H. (2026). SWE-AGI: Benchmarking Specification-Driven Software Construction with MoonBit in the Era of Autonomous Agents. *ArXiv, abs/2602.09447*. <https://doi.org/10.48550/arxiv.2602.09447>
- Zhou, Q., Zhang, J., Wang, H., Hao, R., Wang, J.-H., Han, M., Yang, Y., Wu, S., Pan, F., Fan, L., Tu, D.-D., & Zhang, Z. (2026). FeatureBench: Benchmarking Agentic Coding for Complex Feature Development. *ArXiv, abs/2602.10975*. <https://doi.org/10.48550/arxiv.2602.10975>
- Zhuge, M., Zhao, C., Ashley, D. R., Wang, W.-Y., Khizbullin, D., Xiong, Y., Liu, Z., Chang, E., Krishnamoorthi, R., Tian, Y., Shi, Y.-Y., Chandra, V., & Schmidhuber, J. (2024). Agent-as-a-Judge: Evaluate Agents with Agents. *ArXiv, abs/2410.10934*. <https://doi.org/10.48550/arxiv.2410.10934>